

Desafío - Fundamentos del método científico y probabilidad

En este desafío validaremos nuestros conocimientos de Fundamentos del método científico y probabilidad. Para lograrlo, necesitarás aplicar lo aprendido hasta el momento.

Lee todo el documento antes de comenzar el desarrollo **individual**, para asegurarte de tener el máximo de puntaje y enfocar bien los esfuerzos.

// Tiempo asociado: 1 hora cronológica.

Descripción

Eres analista de datos para una plataforma de streaming de música. Se te ha proporcionado un conjunto de datos que simula la actividad de los usuarios durante un mes. Tu objetivo es utilizar tus conocimientos de probabilidad y técnicas de muestreo para analizar el comportamiento de los usuarios, específicamente en relación con la suscripción al servicio "Premium".

Resultado de Aprendizaje a Evaluar:

Aplicar los principales conceptos de probabilidad asociados a un evento aleatorio según el análisis estadístico.

Instrucciones

Utiliza el siguiente código para generar el conjunto de datos poblacional. Este DataFrame representa a toda tu población de usuarios.

```
Python
import pandas as pd
import numpy as np

np.random.seed(42)

# Crear la población de 1000 usuarios
data = {
    'user_id': range(1, 1001),
    'pais': np.random.choice(['México', 'Colombia', 'Argentina', 'Chile'],
1000, p=[0.4, 0.3, 0.2, 0.1]),
    'tiene_premium': np.random.choice([True, False], 1000, p=[0.35, 0.65])
}
poblacion_df = pd.DataFrame(data)

# Asegurar que algunos usuarios de Chile tengan premium para el cálculo de
intersección
idx_chile = poblacion_df[poblacion_df['pais'] == 'Chile'].index
poblacion_df.loc[np.random.choice(idx_chile, 10, replace=False),
'tiene_premium'] = True
```

Requerimientos

1. Probabilidad Teórica (Sobre la Población Total): (3 Puntos)

- Define los siguientes eventos:
 - **Evento A:** Que un usuario sea de 'Chile'.
 - **Evento B:** Que un usuario tenga una suscripción 'Premium'.
- Calcula las siguientes probabilidades basándote en el DataFrame `poblacion_df`:
 - La probabilidad del Evento A: $P(A)$.
 - La probabilidad del Evento B: $P(B)$.
 - La probabilidad de la **intersección** de ambos eventos: que un usuario sea de 'Chile' **y** tenga 'Premium' $P(A \cap B)$.
 - La probabilidad de la **unión** de ambos eventos: que un usuario sea de 'Chile' **o** tenga 'Premium' $P(A \cup B)$.

2. Muestreo Aleatorio Simple: (2 Puntos)

- Obtén una **muestra aleatoria simple** de 150 usuarios de la población total.
- Sobre esta nueva muestra, calcula la probabilidad empírica de tener 'Premium' $P(B)$.

3. Muestreo Estratificado: (3 Puntos)

- Obtén una **muestra estratificada** de 150 usuarios, asegurando que la proporción de usuarios de cada `pais` en la muestra sea la misma que en la población.
- Sobre esta muestra estratificada, calcula nuevamente la probabilidad empírica de tener 'Premium' $P(B)$.

4. Análisis corto de resultados: (2 Puntos)

- En un comentario (`#`) dentro de tu script, compara las tres probabilidades del evento B (Poblacional, Muestreo Simple, Muestreo Estratificado) que calculaste. Explica brevemente por qué los valores de las muestras pueden diferir del valor poblacional.



¡Mucho éxito!

Estudiante: Valeria Fariña

Programa: Especialización en Fundamentos de Ciencia de Datos

Institución: IGT Chile / Corporación Nueva Ciaspo (SENCE - Talento Digital para Chile)

URL del Repositorio:

https://github.com/ValeriaPFR/Prueba_AnalisisExploratorioDatos_RTD-25-01-13-0058-4.git

Desarrollo

5. Introducción y Objetivos

El presente informe evalúa el comportamiento de una población simulada de 1000 usuarios activos durante el último mes. El objetivo central consiste en cuantificar la probabilidad de adopción del servicio "Premium" y analizar el impacto que tienen las distintas metodologías de muestreo estadístico (Muestreo Aleatorio Simple vs. Muestreo Estratificado) al momento de estimar parámetros poblacionales bajo restricciones de tamaño de muestra ($n = 150$).

6. Estructura de la Población Objeto de Estudio

A partir del modelo probabilístico inicial de la plataforma, la distribución real de los 1000 usuarios según su origen geográfico y tipo de cuenta se detalla a continuación:

- Distribución por País: México (421 usuarios), Colombia (291 usuarios), Argentina (188 usuarios) y Chile (100 usuarios).
- Estado de Suscripción: 346 usuarios poseen una suscripción Premium activa, mientras que 654 usuarios permanecen en la modalidad gratuita.

7. Análisis de Probabilidad Teórica (Población Total)

Definiendo los eventos base como Evento A (Usuario perteneciente a Chile) y Evento B (Usuario con suscripción Premium), se calcularon las siguientes probabilidades exactas sobre el total de la población:

- Probabilidad de pertenecer a Chile $P(A)$:

$$P(A) = \frac{100}{1000} = 0.1000 \quad (10.0\%)$$

- Probabilidad de poseer cuenta Premium $P(B)$:

$$P(B) = \frac{346}{1000} = 0.3460 \quad (34.6\%)$$

- Probabilidad de la Intersección $P(A \cap B)$ (Usuarios de Chile que además son Premium):

$$P(A \cap B) = \frac{37}{1000} = 0.0370 \quad (3.7\%)$$

- Probabilidad de la Unión $P(A \cup B)$ (Usuarios de Chile o que poseen cuenta Premium): Utilizando el teorema de la adición para eventos no mutuamente excluyentes:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$
$$P(A \cup B) = 0.1000 + 0.3460 - 0.0370 = 0.4090 \quad (40.9\%)$$

8. Evaluación de Metodologías de Muestreo ($n = 150$)

Para evaluar la eficiencia de la inferencia, se extrajeron dos subconjuntos independientes de tamaño 150 a partir del marco muestral completo.

A. Muestreo Aleatorio Simple (MAS)

Se seleccionaron 150 usuarios de forma completamente equiprobable mediante un algoritmo de aleatorización pura.

- Resultado obtenido: $P(B)_{\text{simple}} = 0.4133 \quad (41.33\%)$

B. Muestreo Estratificado

Se segmentó la población utilizando la variable "país" como estrato fundamental, asegurando de forma estricta una fracción de muestreo constante del 15% para cada una de las subpoblaciones (respetando la proporción idéntica de la población original).

- Resultado obtenido: $P(B)_{\text{estratificado}} = 0.3267$ (32.67%)

9. Comparación y Discusión Técnica

El análisis comparativo de las tres métricas del Evento B revela variaciones metodológicas críticas:

- Métrica Poblacional Real $P(B)$: 34.60%
- Estimación por Muestreo Simple: 41.33% (Desviación absoluta de +6.73%)
- Estimación por Muestreo Estratificado: 32.67% (Desviación absoluta de -1.93%)

10. Conclusión y explicación del Comportamiento Muestral

Este análisis evaluó con precisión la adopción del servicio "Premium" en la plataforma y contrastó la eficiencia de dos diseños de muestreo para un tamaño de $n = 150$. A nivel de negocio, se determinó una tasa de conversión global del 34.6%, destacando el mercado de Chile por su alta rentabilidad relativa, ya que el 37.0% de sus usuarios pertenece al segmento "Premium".

En el plano metodológico, las discrepancias observadas entre los valores estimados y el parámetro poblacional real se deben al error de muestreo o fluctuación por azar. En el Muestreo Aleatorio Simple, al extraer elementos al azar sin restricciones geográficas, existe una probabilidad alta de subrepresentar o sobrerepresentar determinados segmentos críticos de la población; en este caso práctico, la muestra seleccionó aleatoriamente una proporción más elevada de usuarios Premium, sesgando la tasa hacia el 41.33%. Por el contrario, el Muestreo Estratificado actúa como un mecanismo de control de varianza. Al forzar de manera matemática que cada país mantenga exactamente el mismo peso relativo dentro de la muestra que el que posee en la población real, se neutraliza el sesgo geográfico. Como consecuencia directa, la estimación resultante (32.67%) demostró ser significativamente más cercana, robusta y representativa del comportamiento global de la plataforma.

Asimismo, la integración de una semilla de aleatoriedad (*random_state*) resultó fundamental en el desarrollo del código, asegurando la reproducibilidad exacta del experimento y permitiendo la auditoría de los datos.

Por lo tanto, para el desarrollo de modelos predictivos y análisis de métricas de negocio en la plataforma de streaming, se descarta el uso de muestreos puramente aleatorios cuando existan desequilibrios poblacionales marcados por variables demográficas (como el país de origen). Se recomienda la adopción sistemática de diseños muestrales estratificados para garantizar la estabilidad de los estimadores y reducir el error cuadrático medio en los análisis analíticos posteriores. Comercialmente, la recomendación directa es focalizar estrategias de fidelización en Chile y transferir sus mecánicas de conversión hacia mercados de mayor volumen pero menor penetración actual, como México y Colombia.